

TP - Analisando Grafos do SNAP

Universidade Federal da Bahia (UFBA)
Instituto de Computação

Professor: Bruno Pereira dos Santos
Disciplina: Teoria dos Grafos (MATA53)
Aluno: João Pedro Sales (Matrícula 224215096)
Repositório: <https://github.com/joaopedro-16/tp-mata53-grafos>

Objetivo

Este trabalho tem como objetivo aplicar conceitos da disciplina em um grafo real, realizando tratamento e adaptação de dados, análise estrutural, cálculo de propriedades formais, implementação de algoritmos estudados e interpretação matemática dos resultados.

Determinação do Grafo a ser Utilizado

Com base no registro acadêmico M , o aluno deverá realizar o seguinte cálculo: Dado o número de matrícula M , o estudante deve calcular:

$$f(M) = ((\text{soma dos dígitos de } M) \times (\text{últimos 2 dígitos de } M + 1)) \pmod{129}$$

Se o resultado for 0, considere 129.

Matrícula: 224215096

$$\begin{aligned} f(224215096) &= ((2 + 2 + 4 + 2 + 1 + 5 + 0 + 9 + 6) \times (96 + 1)) \pmod{129} \\ &= (31 \times 97) \pmod{129} \\ &= 3007 \pmod{129} \\ &= 3007/129 \approx 23 \\ &= 23 \times 129 = 2967 \\ &= 3007 - 2967 = 40 \end{aligned}$$

Grafo Selecionado: G40

- **Category:** Citation networks
- **Name:** cit-Patents
- **Name_URL:** <https://snap.stanford.edu/data/cit-Patents.html>
- **Type:** Directed, Temporal, Labeled
- **Nodes:** 3.774.768
- **Edges:** 16.518.948

Tratamento dos Dados e Pré-processamento

A base de dados escolhida para este estudo foi a *US Patent Citation Network* (Rede de Citações de Patentes dos EUA), disponibilizada pelo repositório SNAP (Stanford Network Analysis Project). O conjunto de dados original abrange todas as citações feitas por patentes concedidas entre os anos de 1975 e 1999. O grafo bruto é composto por 3.774.768 vértices e 16.518.948 arestas.

Para viabilizar a análise estrutural e a aplicação dos algoritmos em tempo computacional hábil, foi implementado um *pipeline* de tratamento de dados. As etapas realizadas e suas respectivas justificativas detalham-se a seguir:

1. Lista de Adjacência

- **Tratamento:** Os dados foram carregados em memória RAM utilizando a estrutura de Lista de Adjacência (através da biblioteca NetworkX em Python), descartando a possibilidade de representação por Matriz de Adjacência.
- **Justificativa:** Devido à natureza massiva e esparsa da rede, uma matriz de adjacência exigiria uma complexidade espacial de $O(V^2)$, o que excederia a capacidade de memória disponível e tornaria a execução inviável. A lista de adjacência reduz essa complexidade para $O(V + E)$ otimizando o armazenamento.

2. Grafo Temporal para Grafo Estático

O grafo foi analisado em sua forma estática, representando a união de todas as arestas formadas no período de 1975 a 1999. Nenhuma filtragem temporal adicional (redução de janela de tempo) foi aplicada.

3. Manutenção do Direcionamento (Grafo Dirigido)

- **Tratamento:** Optou-se por não converter o grafo para uma estrutura não direcionada.
- **Justificativa:** Na rede de patentes, a direção da aresta (a patente mais recente cita a patente mais antiga) carrega um peso semântico fundamental de dependência cronológica e tecnológica. Remover o direcionamento invalidaria análises de centralidade baseadas em citações recebidas (*in-degree*) versus citações feitas (*out-degree*).

4. Multigrafo para Grafo Simples

- **Tratamento:** A rede foi instanciada estritamente como um grafo simples direcionado.
- **Justificativa:** Múltiplas citações idênticas entre o mesmo par de patentes (arestas paralelas) são redundantes para cálculos estruturais de alcance e caminhos mínimos. O modelo unifica interações repetidas em uma única conexão lógica.

5. Remoção de Auto-loops

- **Tratamento:** Foi aplicada uma varredura para identificar e remover conexões em que um vértice aponta para si mesmo.
- **Justificativa:** Do ponto de vista semântico e legal, uma patente não pode citar a si mesma como invenção prévia. Qualquer auto-loop presente nos dados brutos representa um ruído ou artefato de coleta que causaria distorções no cálculo de graus e de caminhos.

6. Extração da Maior Componente Conexa

O grafo foi filtrado para reter apenas os vértices e arestas pertencentes à Maior Componente Fracamente Conexa (WCC – *Weakly Connected Component*), que concentra 3.764.117 nós, representando 99,7% da rede original.

1 Parte I - Análise Estrutural

1. Número de Vértices

- Grafo Bruto: 3.774.768 vértices.
- Grafo Tratado (Maior WCC): 3.764.117 vértices.

2. Número de Arestas

- Grafo Bruto: 16.518.948 arestas.
- Grafo Tratado (Maior WCC): 16.511.741 arestas.

3. Grau Mínimo, Máximo e Médio

- **Grau Mínimo:** 0 (Existem nós que receberam citações mas não citaram ninguém, e nós isolados na estrutura bruta).
- **Grau Máximo:**
 - Grau Máximo de Entrada (*In-Degree*): 779
 - Grau Máximo de Saída (*Out-Degree*): 770
 - Grau Máximo Absoluto (Total): 793
- **Grau Médio:** No grafo bruto, o grau médio de entrada/saída é de aproximadamente 4,37 ($16.518.948 / 3.774.768$). Na maior componente, mantém-se muito próximo a 4,38.

4. Distribuição de Graus

A rede de patentes é uma rede de "Mundo Pequeno" (*Scale-Free Network*). A distribuição de graus segue uma Lei de Potência ($P(k) \sim k^{-\gamma}$). Isso significa que a esmagadora maioria das patentes possui pouquíssimas ou nenhuma citação, enquanto uma minoria seleta (*hubs*) concentra milhares de citações.

5. Densidade

- Grafo Bruto: 0.00000116
- Grafo Tratado: aproximadamente 0.00000116.

6. Número de Componentes Conexas e Tamanho

- **Componentes Fracamente Conexas (WCC):** A maior componente possui 3.764.117 nós (99,72% do grafo). O restante dos nós (10.651) está fragmentado em pequenas ilhas isoladas.
- **Componentes Fortemente Conexas (SCC):** A maior possui apenas 1 nó. Como se trata de um Grafo Acíclico Dirigido (DAG) temporal, não existem caminhos de ida e volta entre nós diferentes.

7. Diâmetro e Raio

- **Diâmetro Exato:** 22 (O maior caminho mínimo absoluto encontrado na rede).
- **Diâmetro Efetivo (90-percentil):** 9.4 (Significa que 90% de qualquer par de patentes escolhido ao acaso está a uma distância de no máximo 9.4 passos de citação).
- **Raio:** Não Computado. Exigiria calcular a excentricidade de todos os vértices, o que é computacionalmente inviável.

8. Comprimento Médio dos Caminhos

Valor Aproximado: Fica muito próximo ao diâmetro efetivo (≈ 9.4).

9. Coeficiente de Clusterização Médio e Triângulos

- **Coefficiente de Clusterização Médio:** 0.0757.
- **Número de Triângulos:** 7.515.023 triângulos fechados na rede.

10. Visualização do Grafo (versão reduzida)

Decidi por não renderizar a estrutura completa (que conta com mais de 3,7 milhões de vértices), visto que isso resultaria em uma oclusão visual severa (conhecida na literatura como *hairball effect*) e excederia a capacidade de processamento gráfico padrão, sem agregar valor analítico.

Em vez disso, aplicou-se o método de Amostragem de Rede de Ego (*Ego Network Sampling*). A metodologia adotada seguiu os seguintes passos estruturais:

- **Identificação do Hub Tecnológico:** O algoritmo varreu o grafo tratado para localizar o vértice com o maior grau de entrada (*in-degree*), ou seja, a patente que recebeu o maior número absoluto de citações na rede.
- **Extração do Subgrafo Induzido:** A partir do hub central, extraiu-se um subgrafo contendo o próprio hub e uma amostra de seus vizinhos diretos (patentes predecessoras de 1º grau que o citaram).
- **Algoritmo de Layout:** Utilizou-se o algoritmo de forças direcionadas (*Spring Layout* ou Fruchterman-Reingold). Este modelo simula forças físicas de atração e repulsão para posicionar os nós de forma espacialmente equilibrada, evidenciando a topologia de dependência.

Visualização Reduzida do Grafo: Rede de Ego ao redor do Maior Hub Tecnológico




Figura 1: Visualização Reduzida do Grafo: Rede de Ego ao redor do Maior Hub Tecnológico (HUB: 4723129)

Interpretação do Resultado Visual: A imagem gerada comprova a natureza *Scale-Free* (livre de escala) da rede de inovações tecnológicas. O nó central em destaque (Hub) representa uma patente de altíssima relevância e impacto. Os vértices periféricos representam inovações subsequentes, e as arestas direcionadas (setas convergentes) materializam o fluxo cronológico da dependência tecnológica, onde múltiplas novas invenções se apoiam em um único conhecimento científico basilar.

2 Parte II - Algoritmos da Disciplina

2.1 Classificação e Viabilidade Computacional dos Algoritmos

Para a etapa de aplicação dos algoritmos clássicos de grafos, foi adotada uma metodologia de triagem baseada na viabilidade computacional e na complexidade assintótica (*Big-O*) frente à escala massiva da rede de patentes analisada (aproximadamente 3,76 milhões de vértices e 16,5 milhões de arestas). Devido às limitações físicas de hardware e de tempo de processamento, os algoritmos propostos foram categorizados em três grupos estratégicos:

- **Grupo A (Totalmente Viáveis):** Composto por métodos com complexidade de tempo linear ou quase-linear, como $O(V + E)$ ou $O(V)$. Inclui a Busca em Largura (BFS), Busca em Profundidade (DFS), Verificação de Eulerianidade e o Algoritmo de Tarjan. Estes algoritmos puderam ser executados globalmente ou por amostragem de forma nativa e em tempo hábil, aproveitando eficientemente a estrutura de lista de adjacência na memória RAM.
- **Grupo B (Viáveis com Adaptações e Restrições):** Engloba algoritmos que, embora otimizados, sofrem explosão combinatória ou falha semântica se aplicados em sua forma original. Enquadram-se aqui o Algoritmo de Dijkstra e Kruskal (Árvore Geradora Mínima). Para viabilizá-los, foram exigidas adaptações como a restrição do cálculo de distâncias à fonte única (*Single-Source* em vez de *All-Pairs*), a conversão estrutural para um modelo não direcionado e a atribuição de pesos uniformes fictícios ($w = 1$) às arestas, visto que citações representam custos topológicos discretos.
- **Grupo C (Totalmente Inviáveis):** Constituído por algoritmos de alta complexidade polinomial, como Bellman-Ford $O(V \times E)$ e Floyd-Warshall $O(V^3)$. A aplicação destes métodos foi descartada do experimento prático, pois o volume de operações iterativas necessárias ultrapassa trilhões de ciclos, demandando dias ou anos de processamento ininterrupto. Adicionalmente, restrições espaciais (*Out of Memory*) tornariam impossível a alocação de matrizes densas exigidas por tais métodos. A exclusão deste grupo baseou-se no princípio de que soluções mais eficientes (como a BFS ou Dijkstra adaptado) resolvem o mesmo problema topológico em redes sem arestas de peso negativo.

2.2 Grupo A: Totalmente Viáveis

2.2.1 1. Busca em Largura (Breadth-First Search - BFS)

Análise de Complexidade Teórica

A Busca em Largura (BFS) explora sistematicamente os nós vizinhos de uma raiz em "camadas" (níveis).

- **Tempo:** A complexidade matemática teórica é $O(V + E)$. Isso ocorre porque o algoritmo, no pior cenário, coloca todos os vértices (V) na fila uma única vez e varre todas as arestas de saída (E) de cada vértice retirado da fila para descobrir novos vizinhos.
- **Espaço:** A complexidade espacial é de $O(V)$, pois a estrutura de dados (uma Fila - *Queue*) e o conjunto de vértices já visitados podem crescer até acomodar todos os nós do grafo caso a raiz alcance toda a componente.

Análise de Complexidade Observada (Tempo Real)

Para a validação empírica do tempo de execução, foi desenhado um experimento prático adotando a rede tratada (WCC com $\approx 3,76M$ vértices).

Metodologia do Experimento:

- Sortearam-se 30 vértices distintos de forma aleatória para servirem como raiz da BFS. O uso de raízes aleatórias mitiga o viés topológico, já que, em grafos dirigidos de citações de patentes, algumas raízes não possuem arestas de saída (*out-degree* = 0), resultando em travessias nulas, enquanto grandes *hubs* iniciam buscas maciças.

- Utilizou-se o tamanho de amostra $n = 30$, permitindo a adoção da Distribuição Normal Padrão (Z) pelo Teorema Central do Limite para o cálculo do Intervalo de Confiança (IC). Adotou-se um nível de confiança de 95% ($Z_{\alpha/2} = 1.96$).

Resultados Estatísticos:

$$IC = \bar{x} \pm 1.96 \cdot (\sigma / \sqrt{30})$$

- **Tamanho da Amostra (n):** 30
- **Tempo Médio ($\bar{x}$):** 0.158475 segundos
- **Desvio Padrão (σ):** 0.600389 segundos
- **Margem de Erro:** ± 0.214846 segundos
- **Intervalo de Confiança:** [-0.056371 s, 0.373321 s] (95% de confiança)

2.2.2 2. Busca em Profundidade (Depth First Search - DFS)

Análise de Complexidade Teórica

A Busca em Profundidade (DFS) difere da BFS por adotar uma estratégia agressiva de exploração, mergulhando no caminho mais longo possível de citações antes de realizar o retrocesso (*backtracking*).

- **Tempo:** A complexidade assintótica de tempo permanece idêntica à da BFS, sendo $O(V + E)$. O algoritmo explora todos os vértices acessíveis a partir da raiz e varre todas as suas arestas adjacentes.
- **Espaço:** A complexidade de espaço é de $O(V)$. Em vez de uma Fila, a DFS utiliza uma Pilha (*Stack*) – que na implementação padrão do Python/NetworkX ocorre através da pilha de chamadas recursivas ou iteração explícita. No pior caso (uma rede linear degenerada onde uma patente cita a próxima em sequência única), a pilha armazenaria todos os V vértices.

Análise de Complexidade Observada (Tempo Real)

O experimento foi replicado utilizando a mesma rede conectada de inovações (WCC tratada).

Metodologia do Experimento:

Sorteou-se 30 vértices aleatórios ($n = 30$) para atuarem como raízes da DFS, garantindo que a medição do tempo refletisse travessias heterogêneas no grafo. Devido ao tamanho da amostra estar dentro da condição $n \geq 30$, a estatística inferencial foi calculada utilizando a distribuição Normal, com um nível de confiança fixado em 95% ($Z_{\alpha/2} = 1.96$).

Resultados Estatísticos:

$$IC = \bar{x} \pm 1.96 \cdot (\sigma / \sqrt{30})$$

- **Tamanho da Amostra (n):** 30
- **Tempo Médio ($\bar{x}$):** 0.419928 segundos
- **Desvio Padrão (σ):** 0.419928 segundos
- **Margem de Erro:** ± 0.150269 segundos
- **Intervalo de Confiança:** [-0.072559 s, 0.227980 s] (95% de confiança)

2.2.3 3. Verificação de Eulerianidade

Análise de Complexidade Teórica

A verificação de um Grafo Euleriano direcionado exige que todos os vértices possuam simetria de graus (grau de entrada = grau de saída) e que todos os vértices com grau não nulo pertençam a uma única componente fortemente conexa.

- **Tempo:** No pior caso (onde todos os graus estão corretos e o algoritmo precisa verificar a conectividade forte usando uma varredura DFS), a complexidade seria de $O(V + E)$. No entanto, na implementação adotada (`nx.is_eulerian`), a verificação inicial itera sobre a lista de graus $O(V)$. Ao encontrar a primeira assimetria de graus, o algoritmo interrompe o laço e retorna `False` em $O(1)$ amortizado ou $O(V)$ de tempo linear, o que o torna computacionalmente trivial.
- **Espaço:** A complexidade espacial da checagem é de $O(V)$ para carregar e iterar sobre o vetor de graus dos vértices.

Análise de Complexidade Observada (Tempo Real)

A validação empírica foi realizada executando a função global de checagem euleriana 30 vezes sobre toda a extensão da componente tratada ($\approx 3,76M$ vértices). Não houve sorteio de nós raízes, visto que se trata de uma propriedade estrutural do grafo como um todo.

Metodologia do Experimento e Justificativa Tecnológica:

- Como era matematicamente esperado de um Grafo de Citações de Patentes (uma estrutura direcional acíclica com progressão cronológica), a verificação retornou `False` em todas as instâncias.
- Patentes não podem citar a si mesmas ou invenções futuras, o que impede a formação de ciclos e anula a premissa de que os graus de entrada e saída seriam equivalentes.
- Seguindo o tamanho de amostra exigido ($n \geq 30$), aplicou-se a distribuição Normal (Z) com Nível de Confiança de 95%.

Resultados Estatísticos:

$$IC = \bar{x} \pm 1.96 \cdot (\sigma / \sqrt{30})$$

- **Grafo é Euleriano?** Não.
- **Tamanho da Amostra (n):** 30
- **Tempo Médio ($\bar{x}$):** 0.000027 segundos
- **Desvio Padrão (σ):** 0.000107 segundos
- **Margem de Erro:** ± 0.000038 segundos
- **Intervalo de Confiança:** $[-0.000012 \text{ s}, 0.000065 \text{ s}]$ (95% de confiança)

2.2.4 4. Algoritmo de Tarjan

Análise de Complexidade Teórica

O Algoritmo de Tarjan é um método altamente eficiente baseado em Busca em Profundidade (DFS) para encontrar Componentes Fortemente Conexas (SCCs) em grafos orientados.

- **Tempo:** Sua complexidade teórica é linear em relação ao tamanho da rede, sendo $O(V + E)$. O algoritmo garante que cada vértice é visitado exatamente uma vez pela DFS e cada aresta orientada é inspecionada apenas uma vez durante as atualizações dos valores de amarração (*low-link values*).

- **Espaço:** A complexidade espacial é de $O(V)$. O algoritmo exige o armazenamento de atributos numéricos para cada vértice (estado de descoberta, ID, valor *low-link*), além da manutenção de uma pilha (*Stack*) que, no pior caso, pode chegar a conter todos os vértices do grafo.

Análise de Complexidade Observada (Tempo Real)

Para a validação empírica, o algoritmo foi aplicado globalmente sobre a Maior Componente Fracamente Conexa tratada. Diferentemente da BFS e DFS singulares, o Tarjan é uma operação de varredura integral, não requerendo o sorteio de nós de origem.

Interpretação Estrutural (Topologia do Domínio):

A execução de Tarjan revelou que o grafo possui aproximadamente 3,76 milhões de Componentes Fortemente Conexas isoladas, sendo que a maior delas possui o tamanho exato de 1 vértice. Esse resultado empírico comprova categoricamente que a rede de patentes é um Grafo Acíclico Dirigido (DAG). O algoritmo matematicamente demonstra a impossibilidade cronológica do dado real: inovações seguem uma seta unidirecional do tempo, onde uma patente não pode compor um ciclo de citações com invenções prévias e futuras simultaneamente.

Resultados Estatísticos:

Devido ao processamento massivo exigido pela avaliação de dicionários em Python sobre milhões de vértices e arestas simultaneamente, o tempo de execução absoluto é superior ao das travessias radiais da BFS. A amostra atendeu à exigência metodológica de $n = 30$, permitindo a extração do Intervalo de Confiança via Distribuição Normal ($Z = 1.96$).

$$IC = \bar{x} \pm 1.96 \cdot (\sigma / \sqrt{30})$$

- **Tamanho da Amostra (n):** 30
- **Tempo Médio ($\bar{x}$):** 17.1685 segundos
- **Desvio Padrão (σ):** 2.7707 segundos
- **Margem de Erro:** ± 0.9915 segundos
- **Intervalo de Confiança:** [16.1770 s, 18.1600 s] (95% de confiança)

2.3 Grupo B: Viáveis com Adaptações / Restrições

2.3.1 1. Dijkstra

Análise de Complexidade Teórica e Adaptação

O algoritmo de Dijkstra foi projetado para encontrar os caminhos mínimos em grafos com arestas de pesos não negativos.

- **Inviabilidade do formato "Todos-para-Todos" (All-Pairs):** A complexidade teórica para calcular a distância entre todos os pares possíveis de vértices usando Dijkstra é de $O(V \times (E + V \log V))$. Para a rede de patentes ($V \approx 3,76M$), isso resultaria em trilhões de operações de Fila de Prioridade, tornando a execução computacionalmente impossível em tempo hábil.
- **Adaptação Adotada:** Optou-se pela implementação do Caminho Mínimo de Fonte Única (*Single-Source*). Além disso, como redes de citações são essencialmente não-ponderadas (cada citação representa um passo lógico discreto), atribuiu-se um peso uniforme ($w = 1$) para todas as arestas.
- **Tempo e Espaço:** A complexidade teórica do modelo adotado por execução é de $O(E + V \log V)$, ancorada pelo uso de uma Min-Heap na biblioteca NetworkX. A complexidade de espaço é $O(V)$ para armazenar o vetor de distâncias relaxadas e a árvore de caminhos mínimos.

Análise de Complexidade Observada (Tempo Real)

O experimento foi desenhado simulando 30 cenários distintos de propagação de influência a partir de patentes específicas.

Metodologia do Experimento:

- Foram sorteados aleatoriamente 30 vértices fonte ($n = 30$) na componente tratada.
- Em cada execução, o algoritmo mapeou o custo mínimo da patente-fonte até todas as patentes subsequentes alcançáveis.
- É notável mencionar que, em grafos sem pesos, a Busca em Largura (BFS) soluciona o mesmo problema de forma mais rápida ($O(V + E)$). A medição de tempo do Dijkstra aqui atua como comprovação do *overhead* (custo extra) gerado pela manutenção estrutural do Min-Heap em cenários onde ele não é estritamente necessário.
- Aplicou-se a estatística de inferência com a distribuição Normal ($Z = 1.96$ para 95% de Nível de Confiança).

Resultados Estatísticos:

$$IC = \bar{x} \pm 1.96 \cdot (\sigma / \sqrt{30})$$

- **Tamanho da Amostra (n):** 30
- **Tempo Médio ($\bar{x}$):** 0.000597 segundos
- **Desvio Padrão (σ):** 0.001746 segundos
- **Margem de Erro:** ± 0.000625 segundos
- **Intervalo de Confiança:** [-0.000028 s, 0.001221 s] (95% de confiança)

2.3.2 2. Algoritmo de Árvore Geradora Mínima Prim/Kruskal

Análise de Complexidade Teórica e Adaptação Estrutural

O cálculo de uma Árvore Geradora Mínima (MST) visa conectar todos os vértices de um grafo minimizando o custo total das arestas. Contudo, algoritmos como Kruskal e Prim foram projetados sob a premissa de que a estrutura analisada seja não direcionada e ponderada (possua pesos nas conexões).

- **Adaptação Estrutural:** Para viabilizar a execução, o grafo original direcionado de citações foi matematicamente convertido em um grafo não direcionado simétrico. Adicionalmente, como as citações de patentes não possuem métricas de custo intrínsecas nos dados originais, foi assumido um peso uniforme global ($w = 1$) para todas as arestas.
- **Justificativa da Aplicabilidade Limitada:** Do ponto de vista da teoria dos grafos, aplicar Kruskal em um grafo não ponderado é uma redundância acadêmica. Em uma rede onde todas as arestas têm peso 1, qualquer árvore geradora que conecte a componente será uma Árvore Geradora Mínima com custo total idêntico de $V - 1$. O mesmo resultado topológico poderia ser alcançado executando uma Busca em Largura (BFS) com complexidade muito inferior.
- **Tempo e Espaço:** O algoritmo de Kruskal possui complexidade teórica de $O(E \log E)$ ou $O(E \log V)$. Este gargalo temporal decorre da etapa obrigatória de ordenação das arestas do grafo. O processo de seleção livre de ciclos é gerenciado eficientemente pela estrutura de dados Union-Find em $O(E\alpha(V))$ onde α é o inverso da função de Ackermann. A complexidade espacial foi elevada para $O(V + E)$ devido à necessidade de instanciar a estrutura não direcionada em memória.

Análise de Complexidade Observada (Tempo Real)

A medição empírica testou a capacidade do hardware em ordenar e processar as mais de 16,5 milhões de conexões convertidas.

Metodologia do Experimento:

- O Algoritmo de Kruskal foi executado globalmente 30 vezes sobre a componente gigante adaptada ($n = 30$).

- Como evidência do comportamento esperado da MST, a árvore final retornou exatamente $\approx 3.764.116$ arestas ($V - 1$), comprovando a remoção de todos os ciclos e conexões redundantes da rede de inovações.
- Foi calculada a inferência estatística de tempo baseada na distribuição Normal Padrão ($Z = 1.96$ para um nível de confiança de 95%).

Resultados Estatísticos:

$$IC = \bar{x} \pm 1.96 \cdot (\sigma / \sqrt{30})$$

- **Tamanho da Amostra (n):** 30
- **Tempo Médio ($\bar{x}$):** 157.6510 segundos
- **Desvio Padrão (σ):** 67.4156 segundos
- **Margem de Erro:** ± 24.1243 segundos
- **Intervalo de Confiança:** [133.5267 s, 181.7754 s] (95% de confiança)

2.4 Grupo C: Inviáveis

Para a análise da rede de citações de patentes (*US Patent Citation Network*), a execução dos algoritmos de Bellman-Ford e Floyd-Warshall foi classificada como tecnicamente e matematicamente inviável. A decisão de não implementá-los no escopo prático deste trabalho baseia-se na análise de complexidade espacial e temporal face à magnitude do dataset tratado (maior componente com $\approx 3,76 \times 10^6$ vértices e $\approx 16,5 \times 10^6$ arestas).

Abaixo detalham-se os impeditivos para cada método:

2.4.1 1. Algoritmo de Bellman-Ford

O algoritmo de Bellman-Ford resolve o problema do Caminho Mínimo de Fonte Única (SSSP), possuindo uma complexidade assintótica de tempo de $O(V \times E)$.

- **Projeção Computacional:** Para o grafo de patentes, uma única execução exigiria aproximadamente 6.2×10^{13} operações elementares no pior caso. Mesmo em processadores modernos de alto desempenho, isso representaria dias de processamento ininterrupto por vértice-fonte selecionado.
- **Inviabilidade Semântica/Matemática:** O grande diferencial teórico do Bellman-Ford em relação ao Dijkstra é a sua capacidade de lidar com arestas de pesos negativos e detectar ciclos negativos. Contudo, em uma rede de citações cronológicas, não existem pesos negativos. O peso de uma citação é nulo ou unitário estritamente positivo ($w = 1$).
- **Conclusão:** Sendo a rede restrita a pesos não-negativos, o algoritmo de Dijkstra soluciona o exato mesmo problema de forma exponencialmente mais eficiente ($O(E + V \log V)$). Portanto, a aplicação do Bellman-Ford é redundante e injustificável do ponto de vista da Engenharia de Algoritmos.

2.4.2 2. Algoritmo de Floyd-Warshall

O algoritmo de Floyd-Warshall é desenhado para resolver o problema de Caminhos Mínimos entre Todos os Pares (*All-Pairs Shortest Path*), adotando uma abordagem de Programação Dinâmica.

- **Projeção Temporal ($O(V^3)$):** O algoritmo exige três laços de repetição aninhados iterando sobre todos os vértices. Para $V \approx 3,76 \times 10^6$, o número de operações atinge a escala de $5,3 \times 10^{19}$. Essa ordem de grandeza é impraticável para qualquer hardware computacional de uso civil no horizonte do prazo deste estudo.

- **Projeção Espacial ($O(V^2)$):** O impeditivo mais severo, no entanto, é o consumo de memória (RAM). O Floyd-Warshall exige a alocação de uma matriz de distâncias de tamanho $V \times V$. Uma matriz densa de $3,76 \times 10^6$ por $3,76 \times 10^6$ elementos utilizando números de ponto flutuante padrão (8 bytes) exigiria mais de 100 Terabytes de memória RAM apenas para ser instanciada, o que ultrapassa as restrições físicas de arquiteturas de computadores convencionais.
- **Conclusão:** A restrição drástica de hardware (*Out of Memory*) torna impossível sequer a inicialização das estruturas de dados necessárias para este algoritmo no contexto deste dataset.

3 Parte III - Análise Estrutural Topológica

3.1 1. Análise da Propriedade de Small-World (Mundo Pequeno)

Indícios da Propriedade:

O grafo de patentes apresenta indícios matemáticos contundentes de ser uma rede *Small-World* (modelo de Watts-Strogatz). A validação formal exige que a rede possua uma alta clusterização e caminhos curtos simultaneamente, quando comparada a um grafo aleatório equivalente (modelo de Erdős-Rényi) de mesmo tamanho ($N = 3.764.117$) e grau médio ($k \approx 4.38$). Os resultados empíricos calculados confirmam ambas as condições:

- **Alta Clusterização:** O coeficiente da rede real ($C \approx 0.0757$) mostrou-se aproximadamente 65.000 vezes maior do que a probabilidade do modelo aleatório esperado ($C_{rand} = k/N \approx 0.00000116$).
- **Caminhos Curtos:** O comprimento médio da rede ($L \approx 9.40$) manteve-se da mesma ordem de grandeza e estritamente comparável à projeção teórica aleatória ($L_{rand} = \ln(N)/\ln(k) \approx 10.25$).

Coerência com o Domínio (Faz sentido?):

Sim, este comportamento topológico faz total sentido para uma base de patentes. A clusterização colossal é o reflexo da hiperespecialização científica: invenções de um setor específico (como bioquímica) citam intensamente outras invenções do mesmo nicho, formando "panelinhas" ou densos aglomerados locais de conhecimento. Paralelamente, o comprimento médio curto existe graças às invenções interdisciplinares (grandes *hubs* tecnológicos) que conectam campos de estudo distintos, funcionando como "atalhos" estruturais que unem toda a rede.

Implicação Prática:

A principal implicação de a rede ser um *Small-World* é a eficiência e a velocidade na transferência de conhecimento tecnológico. Isso comprova que a ciência não é fragmentada em silos isolados. Qualquer nova tecnologia de ponta desenvolvida hoje está, em média, a menos de 10 saltos de citação de distância das invenções fundamentais do passado. Essa arquitetura de rede facilita a inovação cruzada (*cross-pollination*), permitindo que métodos ou descobertas de uma área fluam e alavanquem o avanço de outras áreas tecnológicas rapidamente.

3.2 2. Análise da Distribuição de Graus (Lei de Potência)

O Teste Matemático:

Para investigar se a rede de patentes segue uma Lei de Potência, na qual a probabilidade de um vértice ter grau k obedece à proporção $P(k) \sim C \times k^{-\gamma}$, foi calculada a distribuição dos graus de entrada (*in-degree*). Em seguida, projetou-se a frequência desses graus em um gráfico de escala log-log.

O Resultado Empírico:

O gráfico gerado revelou a formação de uma reta decrescente. Matematicamente, quando aplicamos o logaritmo em ambos os lados da equação da Lei de Potência, obtemos a função linear $\log(P(k)) = -\gamma \log(k) + \log(C)$. A aderência dos dados reais a essa reta comprova de forma incontestável que a rede segue uma vigorosa Lei de Potência, caracterizando-se por possuir uma "cauda pesada" (*heavy-tailed distribution*).

Implicação Prática e Sentido Estrutural:

A confirmação desta propriedade classifica a malha de patentes como uma Rede Livre de Escala (*Scale-Free Network*). No mundo real, isso reflete uma severa desigualdade estrutural:

1. **A Maioria Silenciosa:** A esmagadora maioria das patentes (a base do gráfico) possui graus baixíssimos, sendo quase ignoradas ou citadas apenas uma ou duas vezes na história.
2. **A Elite Tecnológica (Hubs):** Uma fração minúscula da rede (a cauda do gráfico) acumula um número massivo de citações (centenas ou milhares).

Esse comportamento é o resultado direto do mecanismo de Ligação Preferencial: ao criar uma nova tecnologia, inventores têm uma propensão muito maior de citar inovações paradigmáticas já consagradas pela indústria, tornando os "nós ricos" (*hubs*) cada vez mais ricos em conexões ao longo do tempo.

3.3 3. Análise de Robustez da Rede

Para avaliar a resiliência estrutural da rede de patentes, simulou-se a remoção de 5% dos vértices (e suas arestas incidentes) sob dois cenários distintos, observando o impacto no tamanho da Maior Componente Conexa (WCC) e no grau de fragmentação do grafo.

Por limitações de viabilidade computacional, a centralidade de *Betweenness* (Intermediação) – que possui complexidade proibitiva para redes na casa dos milhões de nós – foi substituída pela Centralidade de Grau (*Degree Centrality*). Em redes governadas por Leis de Potência, os vértices de maior grau atuam naturalmente como os principais funis (pontes) da rede, tornando essa aproximação altamente acurada e performática.

- **a. Robustez à Remoção Aleatória de 5% (Falha Aleatória):**

O grafo demonstrou-se extremamente robusto a remoções aleatórias. Após a exclusão randômica de 5% dos nós, o tamanho da Maior Componente Conexa sofreu uma redução marginal, e a conectividade global da rede permaneceu quase intacta. Esse comportamento é justificado pela própria distribuição de graus: como a vasta maioria das patentes (mais de 90%) possui graus irrisórios, uma seleção aleatória atinge quase que exclusivamente os "nós periféricos". A remoção dessas patentes isoladas não compromete os caminhos estruturais que mantêm a rede unida.

- **b. Robustez à Remoção dos 5% Mais Centrais (Ataque Direcionado):**

Em contrapartida, o grafo revelou-se altamente vulnerável a um ataque direcionado. Ao remover os 5% dos vértices com maior Centralidade de Grau (os grandes *Hubs* tecnológicos), a rede colapsou estruturalmente. A Maior Componente Conexa esfacelou-se rapidamente, fragmentando o grafo em milhares de pequenos agrupamentos ("ilhas") desconexos.

Interpretação e Conclusão:

Esse contraste severo ($S_{rand} \gg S_{cent}$) consolida o diagnóstico de que a rede de patentes possui a topologia clássica de uma Rede Livre de Escala (*Scale-Free*). O sistema apresenta a propriedade conhecida na literatura como "Robusto, porém Frágil" (*Robust yet Fragile*): a rede sobrevive facilmente ao fracasso ou à irrelevância de milhares de inovações periféricas cotidianas, mas a sua malha de desenvolvimento global depende criticamente e é sustentada por um grupo minúsculo de invenções âncora fundamentais.

3.4 4. A Descoberta Mais Interessante: O Paradoxo da Fragilidade e a Topologia Legal

A descoberta mais fascinante durante a análise desta rede foi constatar como métricas puramente topológicas e matemáticas conseguem espelhar, com exatidão, comportamentos humanos, econômicos e jurídicos do mundo real. Dois pontos se destacaram profundamente nessa intersecção:

1. **O Paradoxo da Fragilidade Tecnológica:** A análise de robustez revelou que o conhecimento científico não é uma malha descentralizada e resiliente em sua totalidade, mas sim uma estrutura de dependência extrema. Foi surpreendente comprovar matematicamente que todo o encadeamento do desenvolvimento tecnológico moderno é sustentado por uma fração minúscula de inovações âncora. A constatação de que a remoção direcionada de apenas 5% das patentes (os grandes *hubs*) é suficiente para desmoronar e fragmentar a Maior Componente Conexa expõe uma vulnerabilidade estrutural fascinante: a ciência avança de forma rápida e conectada (propriedade de *Small-World*), mas é estruturalmente frágil e dependente de seus pilares históricos.

2. **A Topologia Moldada pelo Direito (A Anomalia do Out-Degree):** Outra descoberta marcante ocorreu na extração de métricas básicas, ao identificar a patente com o maior grau de saída (*Out-Degree* de 770 citações feitas por uma única invenção). Inicialmente, sob uma ótica estritamente abstrata, isso parecia um erro de *dataset* ou um *outlier* irreal. Contudo, ao traduzir o dado para o domínio do negócio, constatou-se que esse número massivo reflete uma estratégia corporativa e jurídica defensiva comum no sistema de patentes americano – a citação exaustiva de *Prior Art* (estado da técnica) para evitar futuras invalidações legais do registro.

Essa capacidade da Teoria dos Grafos de não apenas mapear a evolução científica orgânica, mas também de capturar em seus vértices e arestas as pressões jurídicas e as estratégias de mercado, foi, inquestionavelmente, a revelação mais interessante de todo o estudo estrutural.

3.5 5. Aproximação aos Modelos Clássicos de Redes

A análise topológica global da Rede de Citações de Patentes revela que o grafo não se restringe a um único modelo teórico puro, mas aproxima-se fundamentalmente do modelo de Barabási-Albert (BA), complementado pelas propriedades estruturais do modelo de Watts-Strogatz (WS).

Abaixo, detalha-se a aderência e a rejeição aos modelos clássicos:

1. **Rejeição Categórica do Modelo de Erdős-Rényi (Grafo Aleatório):**

O grafo distancia-se completamente do modelo Erdős-Rényi. Redes ER são formadas por conexões estocásticas uniformes, resultando em uma distribuição de graus em formato de sino (Poisson), ausência de *hubs* e um coeficiente de clusterização próximo a zero. As métricas empíricas extraídas (clusterização 65.000 vezes maior que o aleatório e distribuição em Lei de Potência) invalidam qualquer similaridade com este modelo.

2. **O Mecanismo Gerador: Modelo de Barabási-Albert (Ligação Preferencial):**

A rede se aproxima formidavelmente do modelo Barabási-Albert. O modelo BA baseia-se em duas premissas matemáticas que descrevem exatamente a realidade do sistema de patentes dos EUA:

- **Crescimento (Growth):** A rede não é estática; o número de vértices cresce progressivamente ao longo do tempo conforme novas patentes são registradas.
- **Ligação Preferencial (Preferential Attachment):** Novos vértices não se conectam aleatoriamente. Uma nova patente tem uma probabilidade infinitamente maior de referenciar (citar) uma patente fundacional amplamente conhecida e já muito citada (como as patentes base do transistor ou da internet).

É este exato mecanismo – apelidado de “os ricos ficam mais ricos” – que gera a curva da Lei de Potência (comprovada no Item 2) e a extrema vulnerabilidade a ataques direcionados contra *hubs* (comprovada no Item 3).

3. **O Traço Topológico: Modelo de Watts-Strogatz (Mundo Pequeno):**

Embora o modelo BA explique a existência dos *hubs* e a distribuição de graus, ele matematicamente falha em prever a altíssima clusterização que observamos ($C \approx 0.0757$). É aqui que a rede se aproxima do modelo de Watts-Strogatz. A rede de patentes possui blocos de conhecimento hiperespecializados (nichos de biologia, química, mecânica) que formam cliques ou vizinhanças densas, conectados por caminhos curtos globais ($L \approx 9.40$).

Conclusão:

A rede de patentes é uma Rede Livre de Escala (*Scale-Free*). Portanto, o modelo que melhor justifica sua origem e evolução evolutiva é o Barabási-Albert. No entanto, seu estado maduro cristaliza as propriedades de trânsito rápido de informação descritas por Watts-Strogatz.